零声教育出品 Mark 老师 QQ：2548898954

简介

> RocksDB 是 Facebook 的一个实验项目，目的是希望能开发一套能在服务器压力下，真正发挥高速存储硬件性能的高效数据库系统。这是一个 C++ 库，允许存储任意长度二进制 **KV** 数据。支持原子读写操作。
>
> RocksDB 依靠大量灵活的配置，使之能针对不同的生产环境进行调优，包括直接使用内存，使用 Flash，使用硬盘或者 HDFS。支持使用不同的压缩算法，并且有一套完整的工具供生产和调试使用。
>
> RocksDB 大量复用了 **levedb** 的代码，并且还借鉴了许多 HBase 的设计理念。原始代码从 leveldb 1.5 上fork 出来。同时 RocksDB 也借用了一些 Facebook 之前就有的理念和代码。
>
> RocksDB 应用场景非常广泛；比如支持 redis 协议的 pika 数据库，采用 RocksDB 持久化 Redis 支持的数据结构；MySQL 中支持可插拔的存储引擎，Facebook 维护的 MySQL 分支中支持 RocksDB；

编译

RocksDB

```
git clone https://github.com/facebook/rocksdb.git
cd rocksdb
# 编译成调试模式
make
# 编译成发布模式
make static_lib

############################ 使用 cmake ######################
mkdir build
cd build
cmake ..
```

压缩库

Ubuntu

```
# rocksdb 支持多种压缩模式
# gflags
sudo apt-get install libgflags-dev
# snappy
sudo apt-get install libsnappy-dev
# zlib
sudo apt-get install zlib1g-dev
# bzip2
sudo apt-get install libbz2-dev
# lz4
sudo apt-get install liblz4-dev
# zstandard
sudo apt-get install libzstd-dev
```

CentOS

```
# gflags
git clone https://github.com/gflags/gflags.git
cd gflags
```

```
git checkout v2.0
./configure && make && sudo make install
# snappy
sudo yum install snappy snappy-devel
# zlib
sudo yum install zlib zlib-devel
# bzip2
sudo yum install bzip2 bzip2-devel
# lz4
sudo yum install lz4-devel
# ASAN (optional for debugging)
sudo yum install libasan
# zstandard
sudo yum install libzstd-devel
```

基本接口

```
Status Open(const Options& options, const std::string& dbname, DB** dbptr);

Status Get(const ReadOptions& options, const Slice& key, std::string* value);
Status Get(const ReadOptions& options,
                            ColumnFamilyHandle* column_family, const Slice& key,
                            std::string* value);

Status Put(const WriteOptions& options, const Slice& key, const Slice& value);
Status Put(const WriteOptions& options,
                      ColumnFamilyHandle* column_family, const Slice& key,
                      const Slice& value);

// fix read-modify-write 将 读取、修改、写入封装到一个接口中
```

```
Status Merge(const WriteOptions& options, const Slice& key, const Slice& value);
Status Merge(const WriteOptions& options,
                        ColumnFamilyHandle* column_family, const Slice& key,
                        const Slice& value);

// 标记删除，具体在 compaction 中删除
Status Delete(const WriteOptions& options, const Slice& key);
Status Delete(const WriteOptions& options,
                         ColumnFamilyHandle* column_family, const Slice& key,
                         const Slice& ts);

// 针对从来不修改且已经存在的key; 这种情况比 delete 删除的快;
Status SingleDelete(const WriteOptions& options, const Slice& key);
Status SingleDelete(const WriteOptions& options,
                                ColumnFamilyHandle* column_family,
                                const Slice& key);

// 迭代器会阻止 compaction 清除数据，使用完后需要释放;
Iterator* NewIterator(const ReadOptions& options);
Iterator* NewIterator(const ReadOptions& options,

 ColumnFamilyHandle* column_family)
```

高度分层架构

> RocksDB 是一种可以存储任意**二进制KV数据**的嵌入式存储。RocksDB 按顺序组织所有数据，他们的通用操作是 `Get(key)`，`NewIterator()`，`Put(key, value)`，`Delete(Key)` 以及 `SingleDelete(key)`。
>
> RocksDB 有三种基本的数据结构：memtable，sstfile 以及 logfile。memtable 是一种内存数据结构——所有写入请求都会进入 memtable，然后选择性进入 logfile。logfile 是一个在存储上顺序写入的文件。当 memtable 被填满的时候，他会被刷到 sstfile 文件并存储起来，然后相关的 logfile 会在之后被安全地删除。sstfile 内的数据都是排序好的，以便于根据 key 快速搜索。
>
> RocksDB 是基于 lsm-tree (log structured merge - tree) 实现；

LSM-Tree

> LSM-Tree 的核心思想是利用顺序写来提升写性能；LSM-Tree 不是一种树状数据结构，仅仅是一种存储结构；LSM-Tree 是为了写密集型的特定场景而提出的解决方案；如日志系统、海量数据存储、数据分析；
>
> LO 层数据重复，文件间无序，文件内部有序；
>
> L1 ~ LN 每层数据没有重复，跨层可能有重复；文件间是有序的；

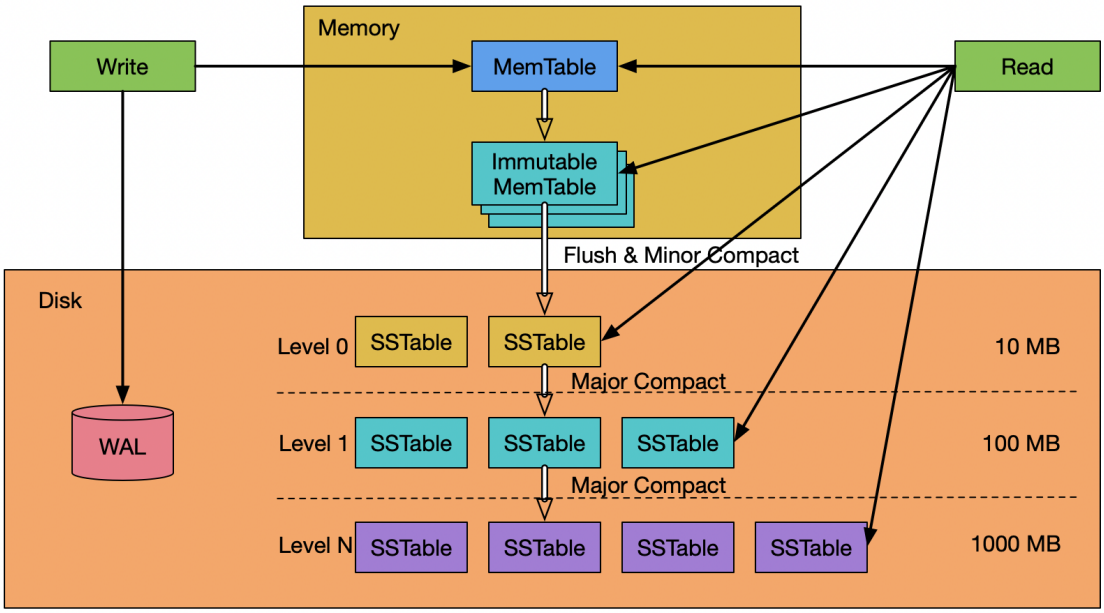

关于访问速度

- 磁盘访问时间：寻道时间 + 旋转时间 + 传输时间；
  - 寻道时间：8ms~12ms；
  - 旋转时间：7200转/min（半周 4ms）；
  - 传输时间：50M/s（约0.3ms）；
- 磁盘随机 IO ≪ 磁盘顺序 IO ≈ 内存随机 IO ≪ 内存顺序 IO；

MemTable

> MemTable 是一个内存数据结构，他保存了落盘到 SST 文件前的数据。他同时服务于读和写——新的写入总是将数据插入到 memtable，读取在查询 SST 文件前总是要查询 memtable，因为 memtable 里面的数据总是更新的。一旦一个 memtable 被写满，他会变成不可修改的，并被一个新的 memtable 替换。一个后台线程会把这个 memtable 的内容落盘到一个 SST 文件，然后这个 memtable 就可以被销毁了。
>
> 默认的 memtable 实现是基于 skiplist 的。
>
> 影响 memtable 大小的选项：

> `write_buffer_size:` 一个 memtable 的大小；
>
> `db_write_buffer_size:` 多个列族的 memtable 的大小总和；这可以用来管理 memtable 使用的总内存数；
>
> `max_write_buffer_number:` 内存中可以拥有刷盘到 SST 文件前的最大 memtable 数；

Memtable类型	SkipList	HashSkipList	HashLinkList	Vector
最佳使用场景	通用	带特殊key前缀的范围查询	带特殊key前缀，并且每个前缀都只有很小数量的行	大量随机写压力
索引类型	二分搜索	哈希+二分搜索	哈希+线性搜索	线性搜索
是否支持全量db有序扫描?	天然支持	非常耗费资源（拷贝以及排序一生成一个临时视图）	同HashSkipList	同HashSkipList
额外内存	平均（每个节点有多个指针）	高（哈希桶+非空桶的skiplist元数据+每个节点多个指针）	稍低（哈希桶+每个节点的指针）	低（vector尾部预分配的内存）
Memtable落盘	快速，以及固定数量的额外内存	慢，并且大量临时内存使用	同HashSkipList	同HashSkipList
并发插入	支持	不支持	不支持	不支持
带Hint插入	支持（在没有并发插入的时候）	不支持	不支持	不支持

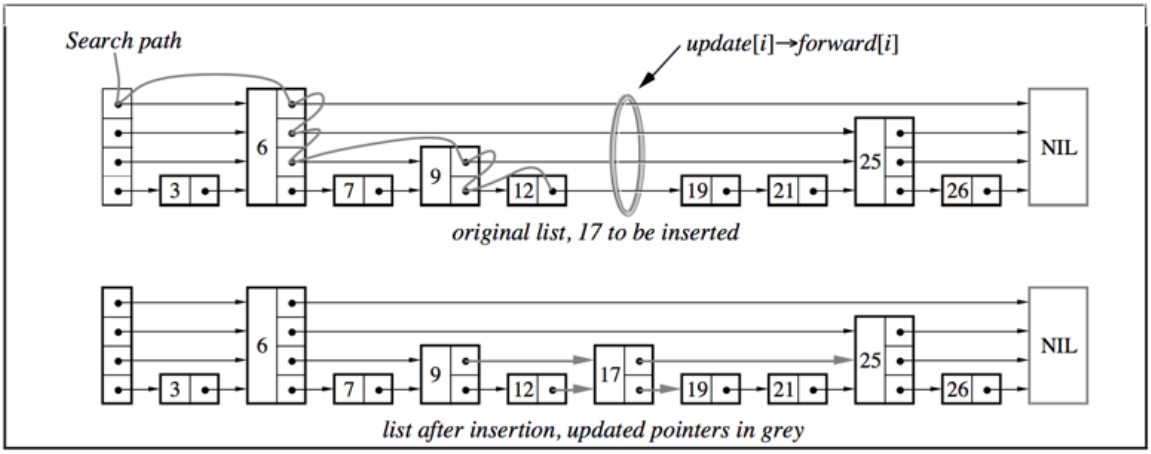

FIGURE 3 - Pictorial description of steps involved in performing an insertion

落盘策略

- Memtable 的大小在一次写入后超过 `write_buffer_size`。
- 所有列族中的 memtable 大小超过 `db_write_buffer_size` 了，或者 `write_buffer_manager` 要求落盘。在这种场景，最大的 memtable 会被落盘；
- WAL 文件的总大小超过 `max_total_wal_size`。在这个场景，有着最老数据的 memtable 会被落盘，这样才允许携带有跟这个 memtable 相关数据的 WAL 文件被删除。

WAL

> RocksDB 中的每个更新操作都会写到两个地方：
>
> 1. 一个内存数据结构，名为 memtable (后面会被刷盘到SST文件)
>
> 2. 写到磁盘上的 WAL 日志。
>
> 在出现崩溃的时候，WAL 日志可以用于完整的恢复 memtable 中的数据，以保证数据库能恢复到原来的状态。在默认配置的情况下，RocksDB 通过在每次写操作后对 WAL 调用 fflush来保证一致性。
>
> WAL 创建时机：
>
> 1. db打开的时候；

> 2. 一个列族落盘数据的时候；（新的创建、旧的延迟删除）

重要参数

- `DBOptions::max_total_wal_size`： 如果希望限制 WAL 的大小，RocksDB 使用 `DBOptions::max_total_wal_size` 作为列族落盘的触发器。一旦 WAL 超过这个大小，RocksDB 会开始强制列族落盘，以保证删除最老的 WAL 文件。这个配置在列族以不固定频率更新的时候非常有用。如果没有大小限制，如果这个WAL中有一些非常低频更新的列族的数据没有落盘，用户可能会需要保存非常老的 WAL 文件。
- `DBOptions::WAL_ttl_seconds`，`DBOptions::WAL_size_limit_MB`：这两个选项影响 WAL 文件删除的时间。非0参数表示时间和硬盘空间的阈值，超过这个阀值，会触发删除归档的WAL文件。

Immutable MemTable

> Immutable MemTable 也是存储在内存中的数据，不过是只读的内存数据；
>
> 当 MemTable 写满后，会被置为只读状态，变成 Immutable MemTable。然后会创建一块新的 MemTable 来提供写入操作；Immutable MemTable 将异步 flush 到 SST 中；

SST

> SST （Sorted String Table） 有序键值对集合；是 LSM-Tree 在磁盘中的数据结构；可以通过建立 key 的索引以及布隆过滤器来加快 key 的查询；LSM-Tree 会将所有的 DML 操作记录保存在内存中，继而**批量顺序**写到磁盘中；这与 B+ Tree 有很大不同，B+ Tree 的数据更新直接需要找到原数据所在页并修改对应值；而 SM-Tree 是直接 append 的方式写到磁盘；虽然后面会通过合并的方式去除冗余无效的数据；

文件格式

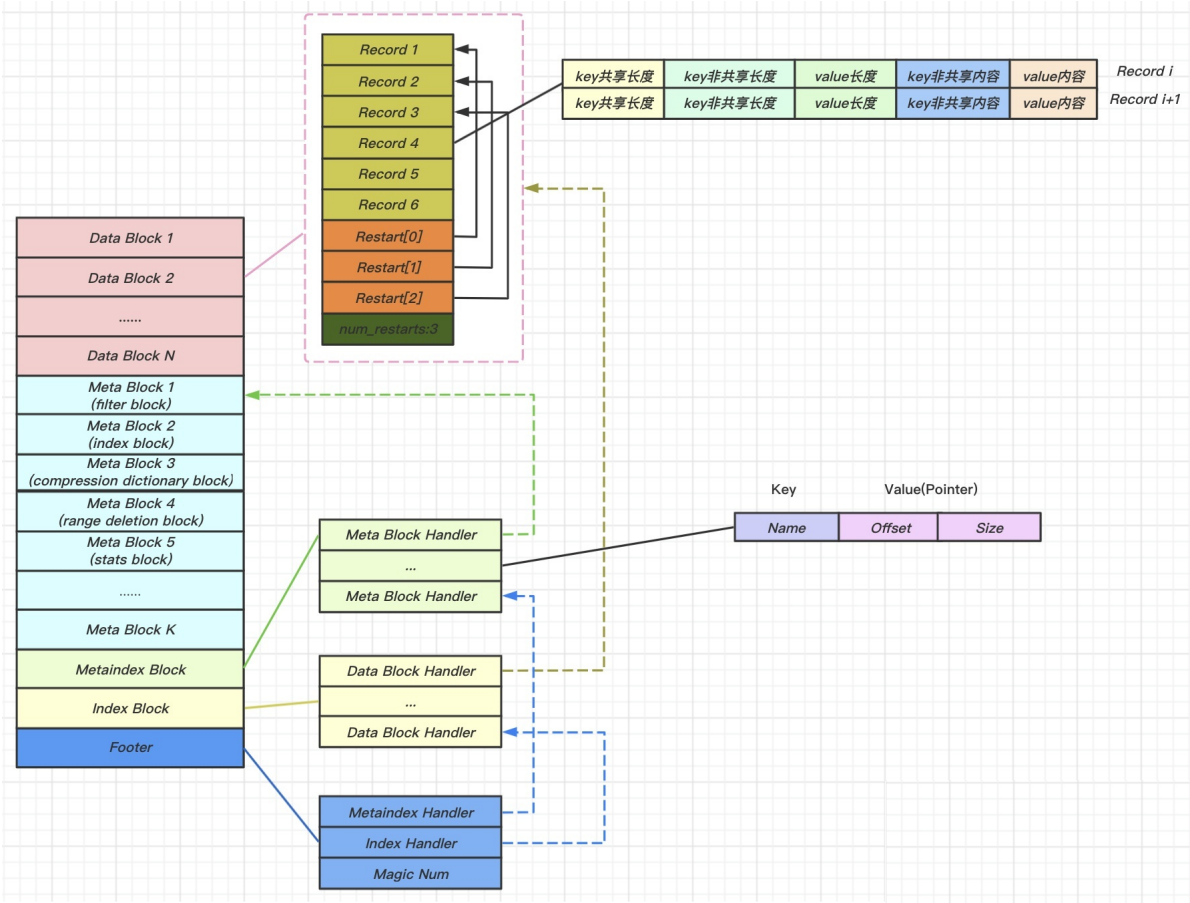


```
<beginning_of_file>
[data block 1]
[data block 2]
...
[data block N]
[meta block 1: filter块]
[meta block 2: stats块]
[meta block 3: 压缩字典块]
[meta block 4: 范围删除块]
...
[meta block K: 未来拓展块]        (我们以后可能会加入新的元数据块)
[metaindex block]
[index block]
[Footer]                          (定长脚注，从file_size - sizeof(Footer)开始)
<end_of_file>
```

`BlockHandle`

```
offset:         varint64
size:           varint64
```

1. 键值对序列在文件中是以排序顺序排列的，并且切分成了一序列的数据块。这些块在文件头一个接一个地排列。每个数据块都根据 `block_builder.cc` 的代码进行编排（参考文件中的注释），然后选择性压缩（compress）；
2. 数据块之后，我们存出一系列的元数据块。支持的元数据块类型在下面描述。更多的数据块类型可能会在以后加入。同样的，每个元数据块都根据 `block_builder.cc` 的代码进行编排（参考文件中的注释），然后选择性压缩（compress）；
3. 一个 metaindex 块对每个元数据块都有一个对应的入口项，key 为meta块的名字，值是一个 BlockHandle ，指向具体的元数据块。
4. 一个索引块，对每个数据块有一个对应的入口项，key 是一个 string，该 string >= 该数据块的最后一个key，并且小于下一个数据块的第一个 key。值是数据块对应的 BlockHandle。如果索引类型 IndexType 是 kTwoLevelIndexSearch，这个索引块就是索引分片的第二层索引，例如，每个入口指向另一个索引块，该索引块包含每个数据块的索引；
5. 在文件的最后，有一个定长的脚注，包含 metaindex 以及索引块的 BlockHandle，同时还有一个魔数：

```
   metaindex_handle: char[p];      // metaindex的Block handle
   index_handle:     char[q];      // 索引块的Block handle
   padding:          char[40-p-q]; // 填充0以达到固定大小
                                   // (40==2*BlockHandle::kMaxEncodedLength)
   magic:            fixed64;      // 0x88e241b785f4cff7 (小端)
```

BlockCache

> 块缓存是 RocksDB 在内存中缓存数据以用于读取的地方。用户可以带上一个期望的空间大小，传一个 Cache 对象给 RocksDB 实例。一个缓存对象可以在同一个进程的多个 RocksDB 实例之间共享，这允许用户控制总的缓存大小。块缓存存储**未压缩过的块**。用户也可以选择设置另一个块缓存，用来存储压缩后的块。读取的时候会先拉去未压缩的数据块的缓存，然后才拉取压缩数据块的缓存。在打开直接 IO 的时候压缩块缓存可以替代 OS 的页缓存。
>
> RocksDB 里面有两种实现方式，分别叫做 LRUCache 和 ClockCache。两个类型的缓存都通过分片来减轻锁冲突。容量会被平均的分配到每个分片，分片之间不共享空间。默认情况下，每个缓存会被分片到 **64** 个分片，每个分片至少有 512 B 空间。
>
> 用户可以选择将索引和过滤块缓存在 BlockCache 中；默认情况下，索引和过滤块都在 BlockCache 外面存储；

```
BlockBasedTableOptions table_options;
table_options.cache_index_and_filter_blocks = true;

std::shared_ptr<Cache> cache = NewLRUCache(capacity);
table_options.block_cache = cache;
Options options;
options.table_factory.reset(new BlockBaseTableFactory(table_options));
```

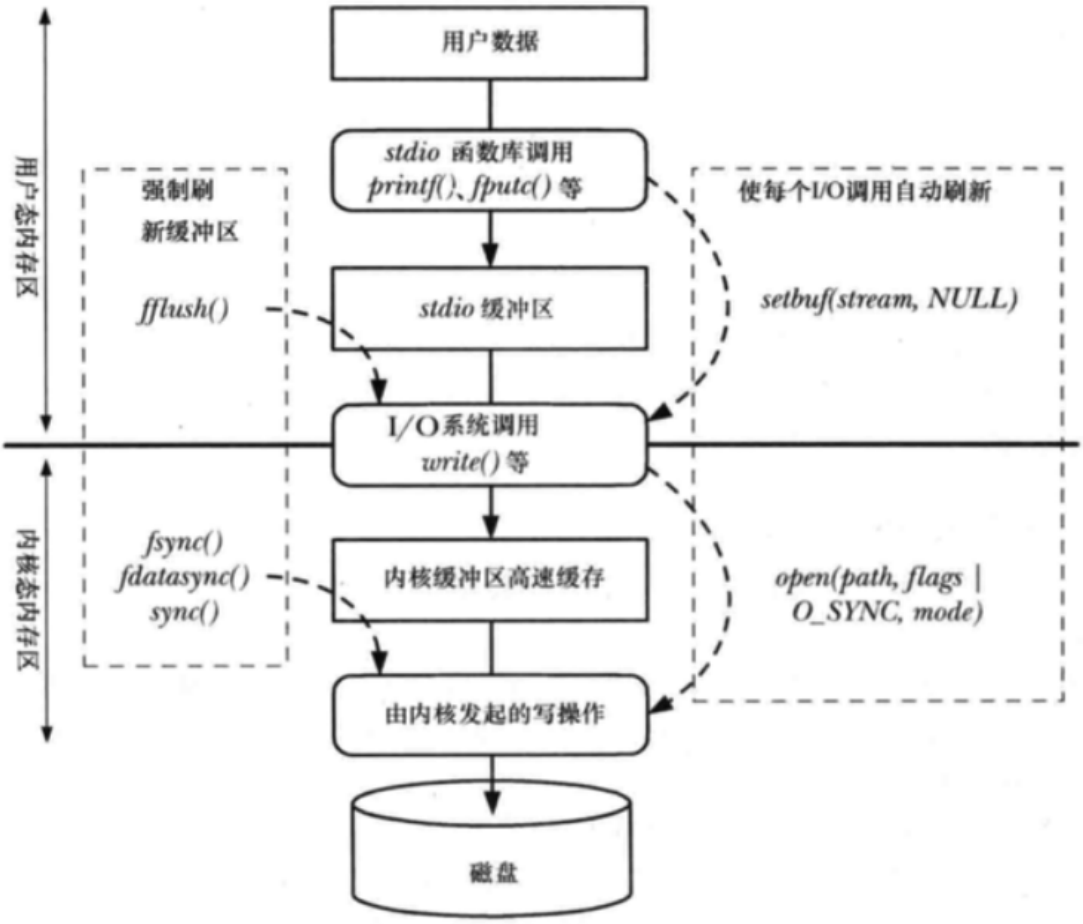

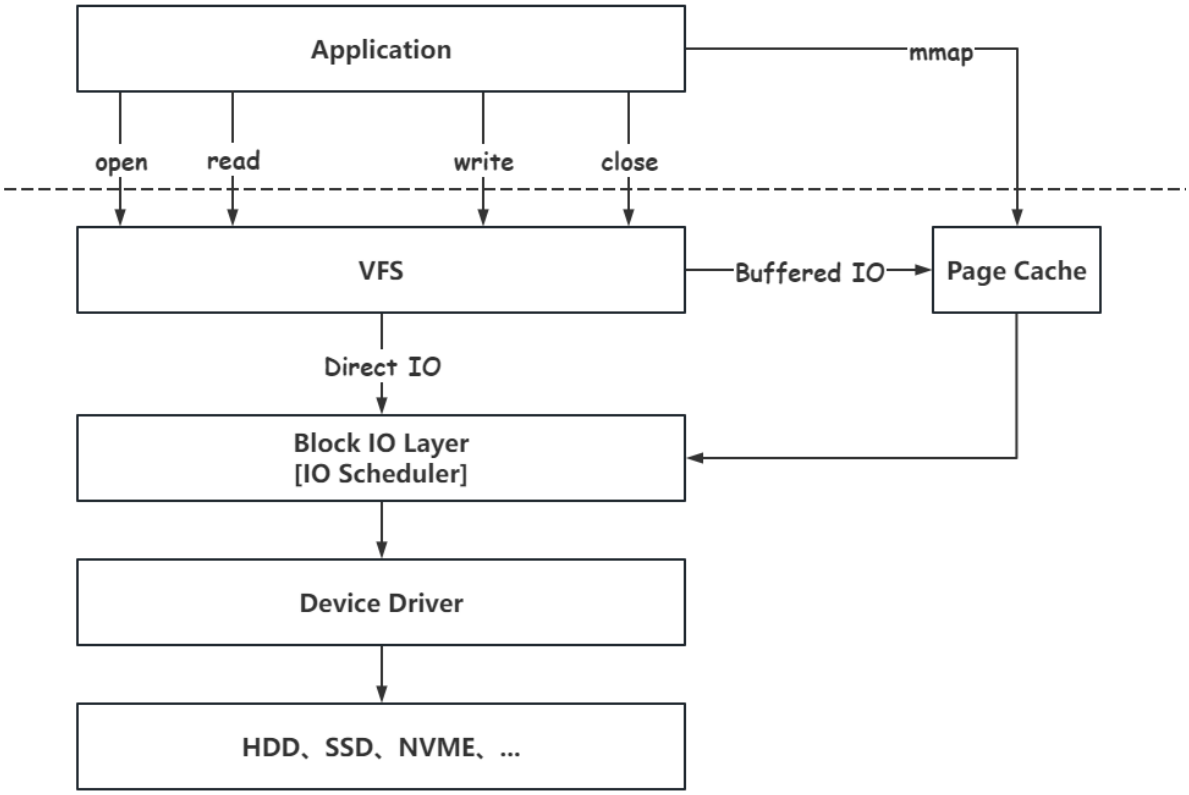

LRU 缓存

> 默认情况下，RocksDB 会使用 LRU 块缓存实现，空间为 8MB。每个缓存分片都维护自己的 LRU 列表以及自己的查找哈希表。通过每个分片持有一个互斥锁来实现并发。不管是查找还是插入，都需要申请该分片的互斥锁。用户可以通过调用 `NewLRUCache` 创建一个 LRU 缓存；

Clock缓存

> ClockCache 实现了[CLOCK算法](#)。每个clock缓存分片都维护一个缓存项的环形列表。一个clock指针遍历这个环形列表来找一个没有固定(unpinned block)的项进行驱逐，同时，如果在上一个扫描中他被使用过了，那么给予这个项两次机会来留在缓存里。`tbb::concurrent_hash_map` 被用来查找数据。
>
> 与 LRU 缓存比较，clock 缓存有更好的锁粒度。在 LRU 缓存下面，每个分片的互斥锁在读取的时候都需要上锁，因为他需要更新他的 LRU 列表。在一个 clock 缓存上查找数据不需要申请该分片的互斥锁，只需要搜索并行的哈希表就行了，所以有更

> 好锁粒度。只有在插入的时候需要每个分片的锁。用 clock 缓存，在一定环境下，我们能看到读性能的增长；

写入流程

1. 写入位于磁盘中的 WAL（Write Ahead Log）里。
2. 写入`memtable`。
3. 当大小达到一定阈值后，原有的`memtable`冻结变成`immutable`。后续的写入交接给新的`memtable`和WAL。
4. 后台开启 Compaction 线程，开始将`immutable`落库变成一个 L0 层的`SSTable`，写入成功后释放掉以前的 WAL。
5. 若插入新的`SSTable`后，当前层（`Li`）的总文件大小超出了阈值，会从`Li`中挑选出一个文件，和`Li+1`层的重叠文件继续合并，直到所有层的大小都小于阈值。合并过程中，会保证`L1`以后，各`SSTable`的Key不重叠。

读取流程

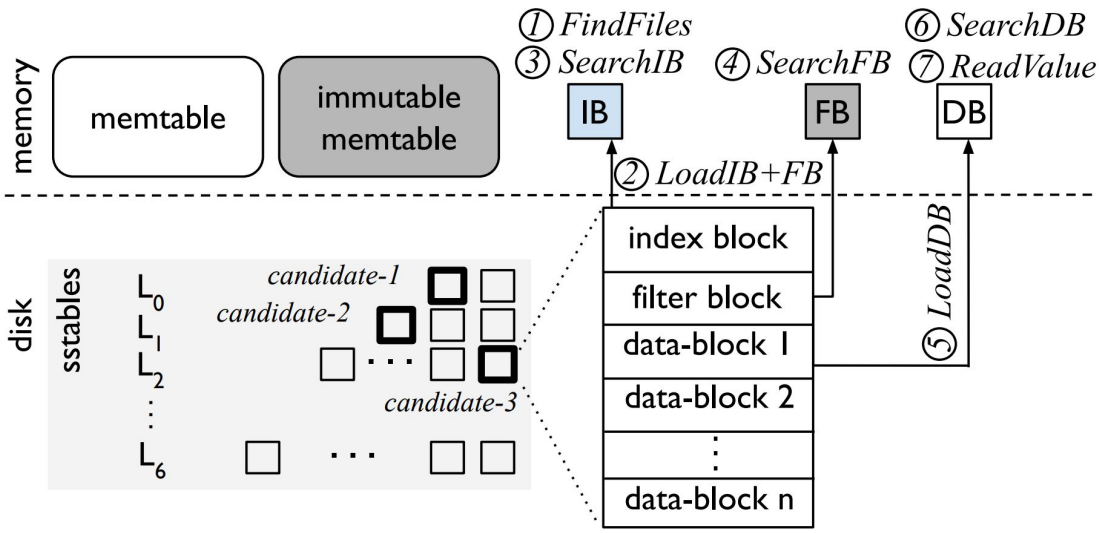

1. `FindFiles`。从SST文件中查找，如果在 L0，那么每个文件都得读，因为 L0 不保证Key不重叠；如果在更深的层，那么Key保证不重叠，每层只需要读一个 SST 文件即可。L1 开始，每层可以在内存中维护一个 SST的有序区间索引，在索引上二分查找即可；

2. `LoadIB + FB`。IB 和 FB 分别是 `index block` 和 `filter block` 的缩写。`index block`是SST内部划分出的block的索引；`filter block` 则是一个布隆过滤器（Bloom Filter），可以快速排除 `Key` 不在的情况，因此首先加载这两个结构；
3. `SearchIB`。二分查找 `index block`，找到对应的`block`；
4. `SearchFB`。用布隆过滤器过滤，如果没有，则返回；
5. `LoadDB`。则把这个`block`加载到内存；
6. `SearchDB`。在这个`block`中继续二分查找；
7. `ReadValue`。找到 `Key`后读数据，如果考虑 WiscKey KV分离的情况，还需要去 vLog 中读取；

LSM-Tree 三大问题

> Amplification
>
> - Write amplification is the multiple of bytes written by the database to bytes changed by the user. Since some LSM trees rewrite unchanging data over time, write amplification can be high in LSM trees.
> - Read amplification is how many bytes the database has to physically read to return values to the user, compared to the bytes returned. Since LSM trees may have to look in several places to find data, or to determine what the data’s most recent value is, read amplification can be high.
> - Space amplification is how many bytes of data are stored on disk, relative to how many logical bytes the database contains. Since LSM trees don’t update in place, values that are updated often can cause space amplification.

读放大

> 用来描述数据库必须物理读取的字节数相较于返回的字节数之比。和数据分层存放，读取操作也需要分层依次查找，直到找到对应数据；这个过程可能涉及多次 IO；在 range query 的时候，影响更大；

空间放大

> 用来描述磁盘上存储的数据字节数相较于数据库包含的逻辑字节数之比；所有的写入操作都是顺序写，而不是就地更新，无效数据不会马上被清理掉；

写放大

> 用来描述实际写入磁盘的数据大小和程序要求写入的数据大小之比；为了减小读放大和空间放大，RocksDB 采用后台线程合并数据的方式来解决；这些合并过程中会造成对同一条数据多次写入磁盘；

RocksDB compaction

> 为了在读放大、空间放大、以及写放大之间进行取舍，以此适应不同的业务场景；所以需要选择不同的合并算法；rocksdb 默认采用 leveled compaction（leveled & tiered）；

leveled compaction

sst 组织方式：

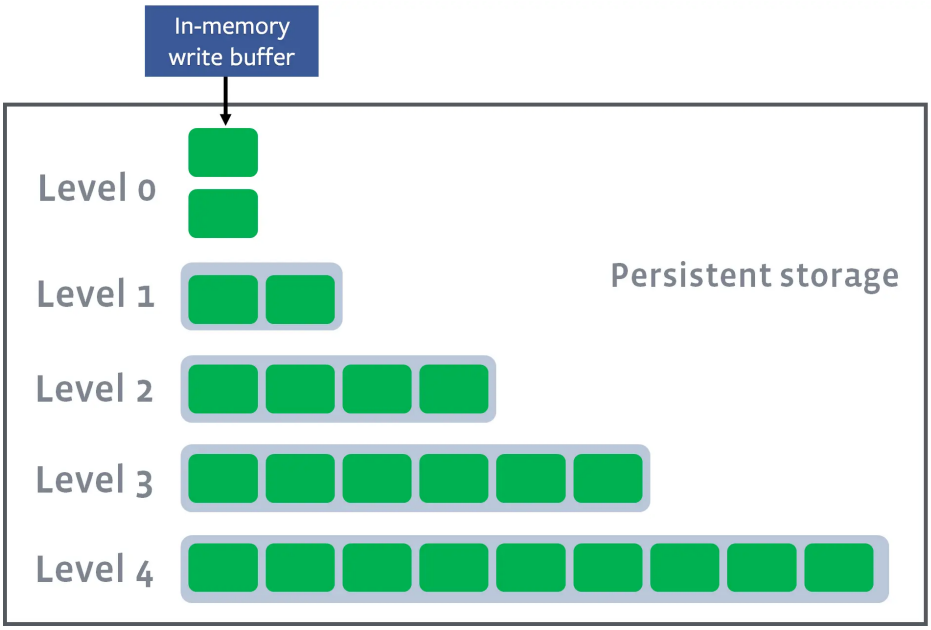

`L1 -> Ln` **按序分片，保存不同文件：**

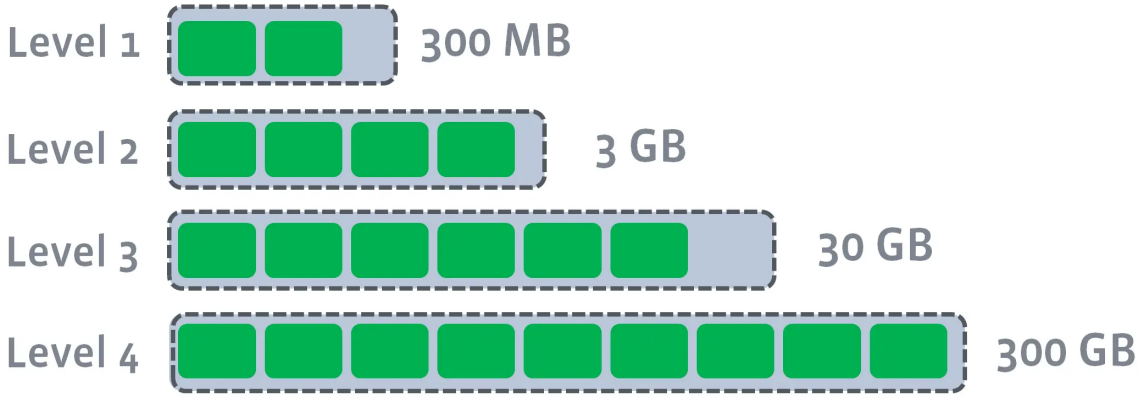

`L0 -> L1` **compaction：**

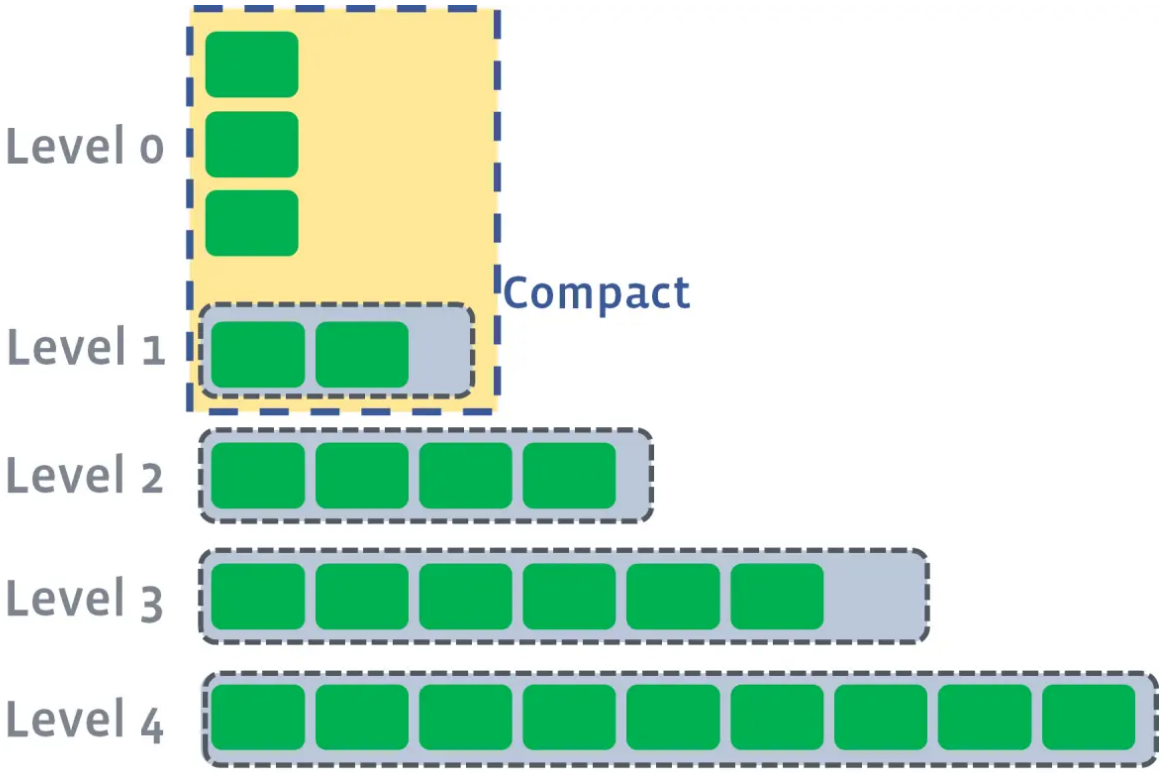

`L1 -> L2 compaction:`

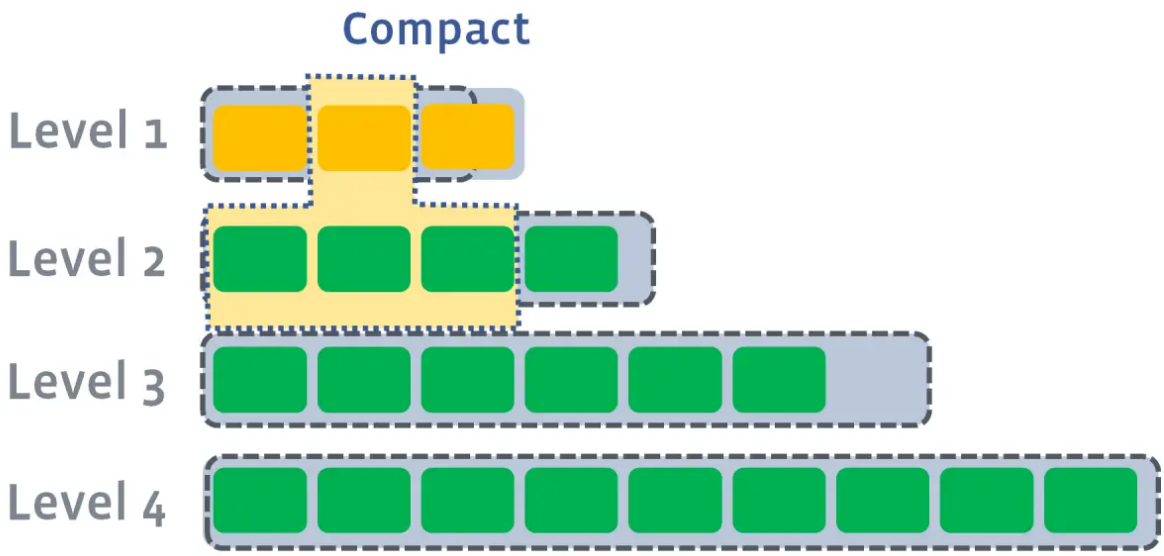

合并后:

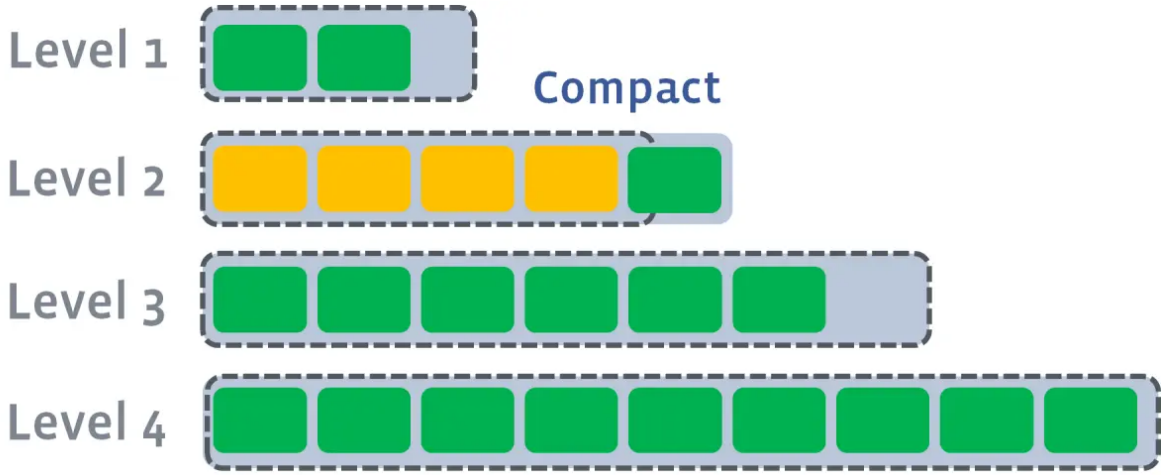

`L2 -> L3 compaction:`

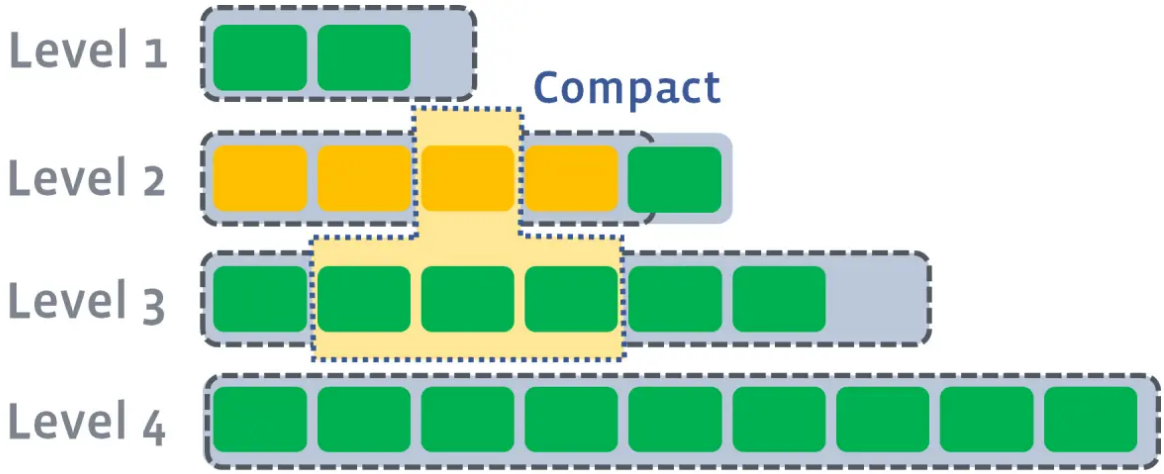

合并后：

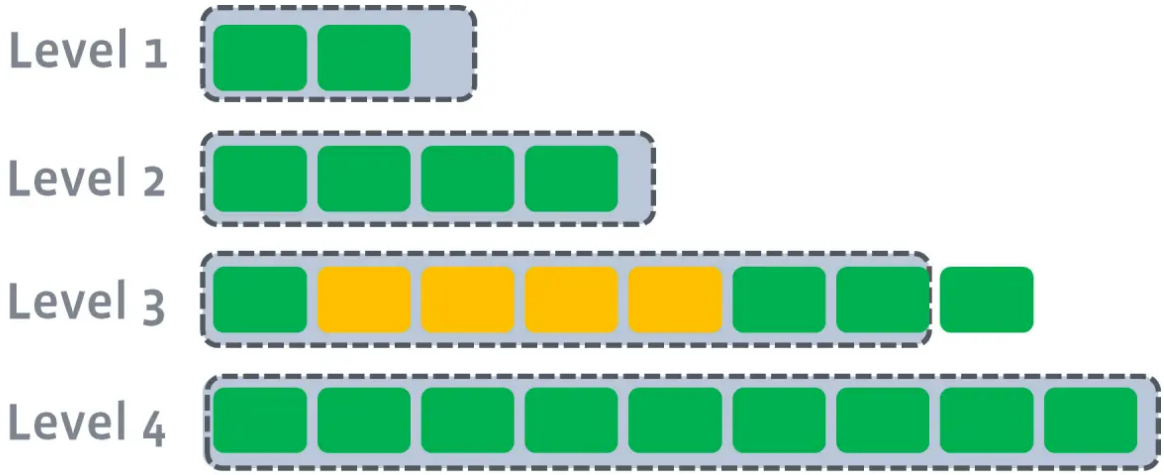

并行 compaction：

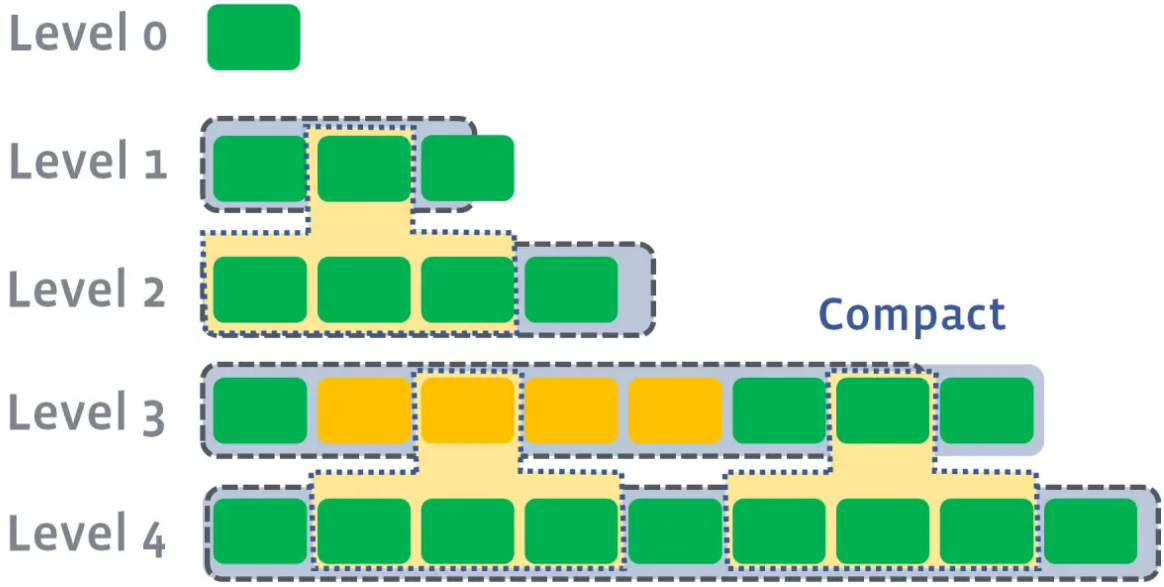

`L0 subcompaction:`

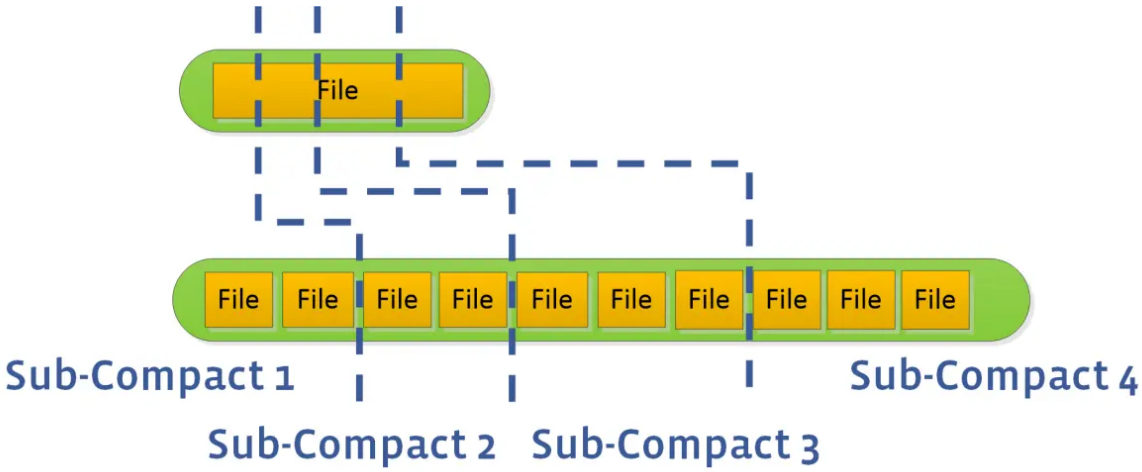

> L0 向 L1 的 compaction 不可以与其他 level 进行并行 compaction。这将成为整体 compaction 的瓶颈；可以通过设置 `max_subcompactions` 来加速 L0 到 L1 的 compaction；

列族（column family）

> RocksDB 的每个键值对都与唯一一个列族（column family）结合。如果没有指定 Column Family，键值对将会结合到 “default” 列族。
>
> 列族提供了一种从逻辑上给数据库分片的方法。他的一些有趣的特性包括：
>
> - 支持跨列族原子写。意味着你可以原子执行 `Write({cf1,key1,value1},{cf2,key2,value2})`。
> - 跨列族的一致性视图。
> - 允许对不同的列族进行不同的配置
> - 即时添加 / 删除列族。两个操作都是非常快的。
>
> **实现：**
>
> 列族的主要实现思想是他们共享一个 WAL 日志，但是不共享 memtable 和 table 文件。通过共享 WAL 文件实现了原子写。通过隔离 memtable 和 table 文件，我们可以独立配置每个列族并且快速删除它们。
>
> 每当一个单独的列族刷盘，我们创建一个新的 WAL 文件。所有列族的所有新的写入都会去到新的 WAL 文件。但是，我们还不能删除旧的 WAL，因为他还有一些对其他列族有用的数据。我们只能在所有的列族都把这个 WAL 里的数据刷盘了，才能删除这个 WAL 文件。这带来了一些有趣的实现细节以及一些有趣的调优需求。确保你的所有列族都会有规律地刷盘。另外，看一下 `Options::max_total_wal_size`，通过配置他，过期的列族能自动被刷盘。

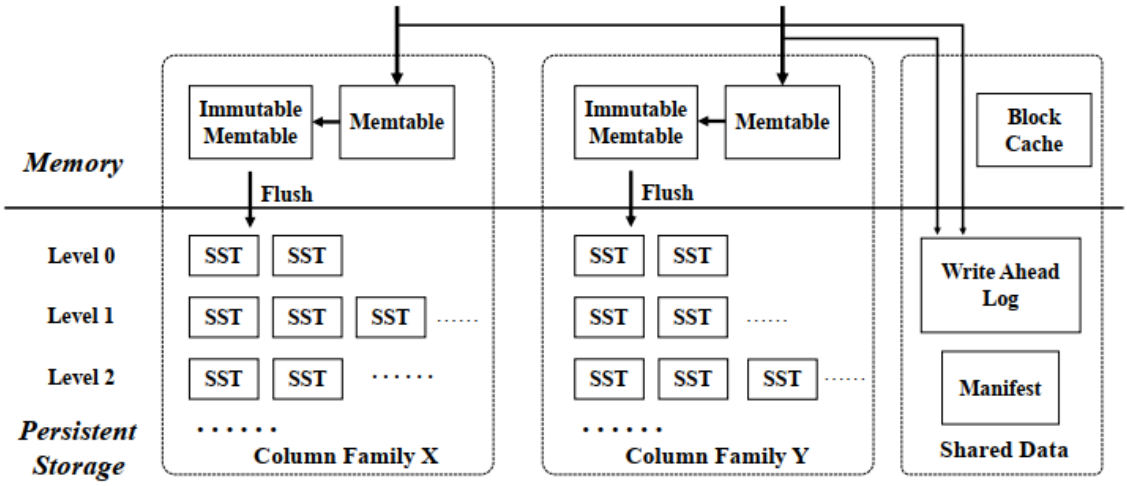

Figure 1: The basic architecture of RocksDB.

快照（snapshot）

> 一个快照会捕获在创建的时间点的 DB 的一致性视图。快照在 DB 重启之后将消失。
>
> 一个快照相当于一个 `SnapshotImpl` 类的小型对象。他只持有部分简单的字段，比如快照生成时候的 `number_` 以及 `unix_time_`。
>
> **实现：**
>
> Snapshot 会存储在一个 `DBImpl` 持有的链表里。其中一个好处是，我们可以在获取 DB 互斥锁前分配好这个链表的节点。然后在持有互斥锁的时候，我们只需要更新链表指针。更进一步，`ReleaseSnapshot` 可以对所有的快照以任意顺序被调用。使用链表，我们不需要移动所有节点就可以删除一个节点了。
>
> **问题：**
>
> 快照具有伸缩性的问题；因为使用链表。尽管他是顺序排列的，他还是不可以使用二分查找。在 flush/compaction 的时候，如果我们需要找到一个 key 在最早的哪个 snapshot 中是可见的，我们必须逐个扫描快照链表。当许多快照存在的时候，

> 这个扫描会非常明显的拖慢 flush/compaction 线程。当有成百上千个快照的时候就能观察到这种问题了。

迭代器(scan)

> 如果 `ReadOptions.snapshot` 被给出，那么迭代器会从一个快照里面返回数据。如果这是一个 nullptr，迭代器隐式创建一个迭代器创建的时间节点的快照，利用该隐式快照提供数据。隐式快照无法转换为显式快照。

事务

> 当使用 TransactionDB 或者 OptimisticTransactionDB 的时候，RocksDB 将支持事务。事务带有简单的 `BEGIN/COMMIT/ROLLBACK` API，并且允许应用并发地修改数据，具体的冲突检查，由 RocksDB 来处理。RocksDB 支持悲观和乐观的并发控制。
>
> 注意，当通过 `WriteBatch` 写入多个 key 的时候，RocksDB 提供原子化操作。事务提供了一个方法，来保证他们只会在没有冲突的时候被提交。与 `WriteBatch` 类似，只有当一个事务提交，其他线程才能看到被修改的内容（读 committed）。

悲观事务（TransactionDB）

> 当使用 TransactionDB 的时候，所有正在修改的 RocksDB 里的 key 都会被上锁，让 RocksDB 执行冲突检测。如果一个 key 发生锁冲突，操作会返回一个错误。当事务被提交，数据库保证这个事务是可以写入的。
>
> 一个 TransactionDB 在有大量并发工作压力的时候，相比 OptimisticTransactionDB 有更好的表现。然而，由于非常过激的上锁策略，使用 TransactionDB 会有一定的性能损耗。TransactionDB 会在所有写操作的时候做冲突检查，包括不使用事务写入的时候。

乐观事务（OptimisticTransactionDB）

> 乐观事务提供轻量级的乐观并发控制，用来给那些多个事务间不会有高的竞争或者干涉的工作场景。
>
> 乐观事务在预备写的时候不使用任何锁。作为替代，他们把这个操作推迟到在提交的时候检查，是否有其他人修改了正在进行的事务。如果和另一个写入有冲突（或者他无法做决定），提交会返回错误，并且没有任何 key 都不会被写入。
>
> 乐观的并发控制在处理那些偶尔出现的写冲突非常有效。然而，对于那些大量事务对同一个 key 写入导致写冲突频繁发生的场景，却不是一个好主意。对于这些场景，使用 TransactionDB 是更好的选择。OptimisticTransactionDB 在大量非事务写入，而少量事务写入的场景，会比 TransactionDB 性能更好。

底层实现

> **读快照：**
>
> 每一个 RocksDB 的更新都是通过插入一个带有强制自增的序列号的项来实现的。给即将要被（事务或者非事务）DB 用来创建快照的 read_options。snapshot赋值一个序列号，可以只读到小于这个序列号的内容。
>
> **读写冲突检测：**
>
> 读写冲突可以通过升级为写写冲突来防止：通过 `GetForUpdate`（而不是`Get`）来做读操作。
>
> select * from t where ... for update 加X锁 当前读
>
> **写写冲突检测（悲观）：**
>
> 写写冲突在写入的时候用一个锁表来进行检测。非事务更新（put，merge，delete）在内部其实是以一个事务来运行的。

> **写写冲突检测（乐观）：**
>
> 写写冲突会在提交的时候检查其最后一个序列号，来检测冲突。
>
> 冲突检测的逻辑在 `TransactionUtil::CheckKeysForConflicts` 中实现；
>
> - 只检测在内存中出现的 key 的冲突和失败。
> - 冲突检测是通过比对每个 key 的最后的序列号（`DBImpl::GetLatestSequenceForKey`）与用于写入的序列号来实现的。